数据库拆分与一致性哈希算法
Scaling Database & Consistent Hashing

课程版本 v6.0　　本节主讲人 东邪

扫描二维码关注微信/微博
获取最新面试题及权威解答

微信: ninechapter
微博: http://www.weibo.com/ninechapter
知乎: http://zhuanlan.zhihu.com/jiuzhang
官网: http://www.jiuzhang.com

Interviewer: How to scale?

当访问量越来越大以后，如何让你的系统 Scale？

How to scale system ≈ How to scale database

除了QPS，还有什么需要考虑的？

假如用户的 QPS 有 1k

Database 和 Web Server 假设也均能够承受 1k 的 QPS

还有什么情况需要考虑？

单点失效
Single Point Failure

万一这一台数据库挂了

短暂的挂：网站就不可用了

彻底的挂：数据就全丢了

所以你需要做两件事情

1. 数据拆分 Sharding（又名 Partition）
2. 数据复制 Replica

数据拆分 Sharding

又名 Partition

方法：按照一定的规则，将数据拆分开存储在不同的实体机器上。

意义：

1. 挂了一台不会全挂
2. 分摊读写流量

数据复制 Replica

方法:一式三份(重要的事情写三遍)

意义:

1. 一台机器挂了可以用其他两台的数据恢复

2. 分摊读请求

Sharding in SQL vs NoSQL

数据拆分与数据库的类型无关

无论是 SQL 还是 NoSQL 都可以进行数据拆分

大部分的 NoSQL 已经帮你写好了拆分算法

数据拆分 Sharding

纵向拆分 Vertical Sharding

横向拆分 Horizontal Sharding

纵向切分
Vertical Sharding

User Table 放一台数据库

Friendship Table 放一台数据库

Message Table 放一台数据库

...

稍微复杂一点的 Vertical Sharding

- 比如你的 User Table 里有如下信息
  - email
  - username
  - password
  - nickname // 昵称
  - avatar // 头像
- 我们知道 email / username / password 不会经常变动
- 而 nickname, avatar 相对来说变动频率更高
- 可以把他们拆分为两个表 User Table 和 UserProfile Table
  - UserProfile 中用一个 user_id 的 foreign key 指向 User
  - 然后再分别放在两台机器上
  - 这样如果 UserProfile Table 挂了，就不影响 User 正常的登陆

提问

Vertial Sharding 的缺点是什么？

不能解决什么问题？

横向切分
Horizontal Sharding

核心部分！

Scale 的核心考点！

猜想1:新数据放新机器，旧数据放旧机器

比如一台数据库如果能放下 1T 的数据

那么超过1T之后就放在第二个数据库里

以此类推

问:这种方法的问题是什么？

数据访问不均匀

猜想2：对机器数目取模

假如我们来拆分 Friendship Table

我们有 3 台数据库的机器

于是想到按照 from_user_id % 3 进行拆分

这样做的问题是啥？

假如 3 台机器不够用了

我现在新买了1台机器

原来的%3，就变成了%4

几乎所有的数据都要进行位置大迁移

过多的数据迁移会造成的问题

1. 慢，容易造成数据的不一致性

2. 迁移期间，服务器压力增大，容易挂

直接 %n（机器总数）的方法

- % n 的方法是一种最简单的 Hash 算法
  - 但是这种方法在 n 变成 n+1 的时候，每个 key % n和 % (n+1) 结果基本上都不一样
  - 所以这个 Hash 算法可以称之为：不一致 hash

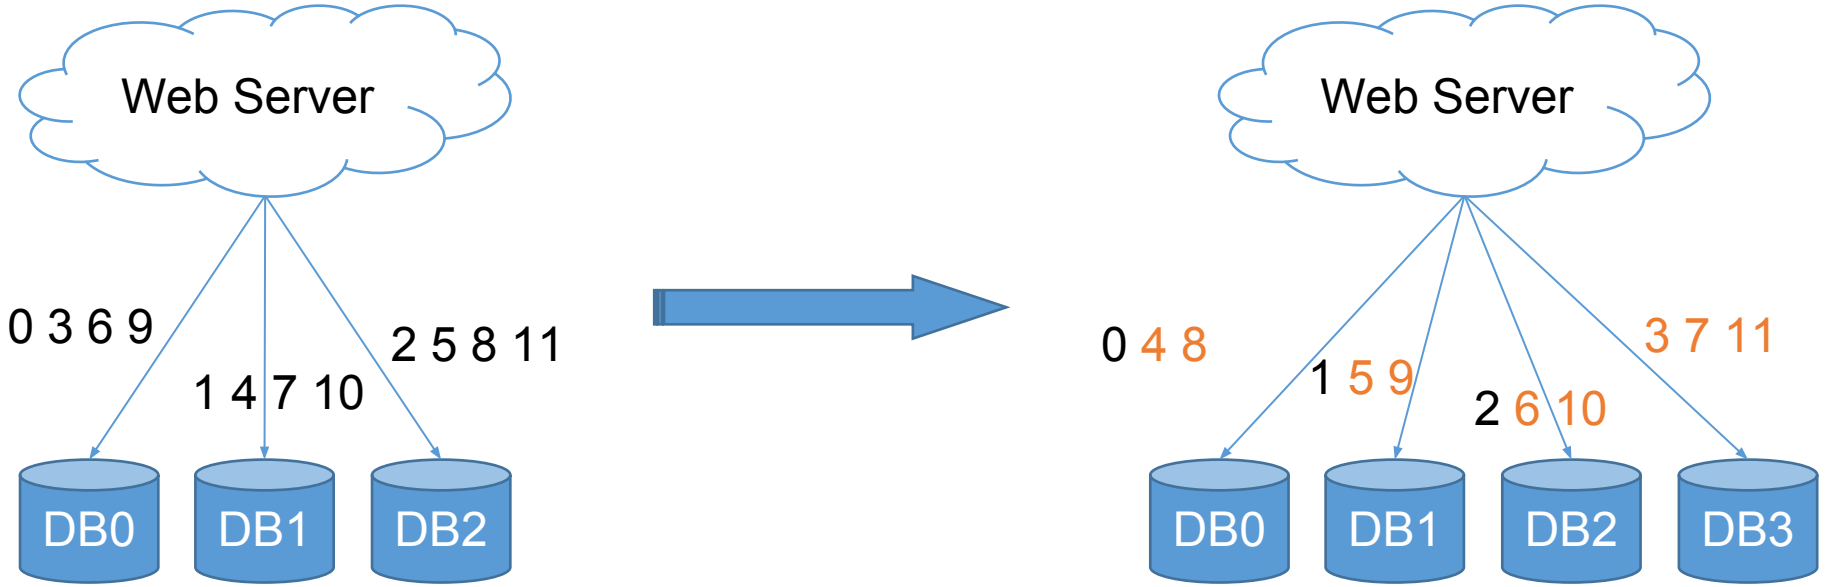

怎么办？

一致性 Hash 算法

Consistent Hashing

一致性哈希算法
Consistent Hashing

Horizontal Sharding 的秘密武器

无论是 SQL 还是 NoSQL 都可以用这个方法进行 Sharding

注：大部分 NoSQL 都帮你实现好了这个算法，帮你自动 Sharding

很多 SQL 数据库也逐渐加入 Auto-scaling 的机制了，也开始帮你做自动的 Sharding

一致性哈希算法 Consistent Hashing

- 我们先来说说为什么要做 “一致性”Hash
  - % n 的方法是一种最简单的 Hash 算法
  - 但是这种方法在 n 变成 n+1 的时候，每个 key % n和 % (n+1) 结果基本上都不一样
  - 所以这个 Hash 算法可以称之为：不一致 hash

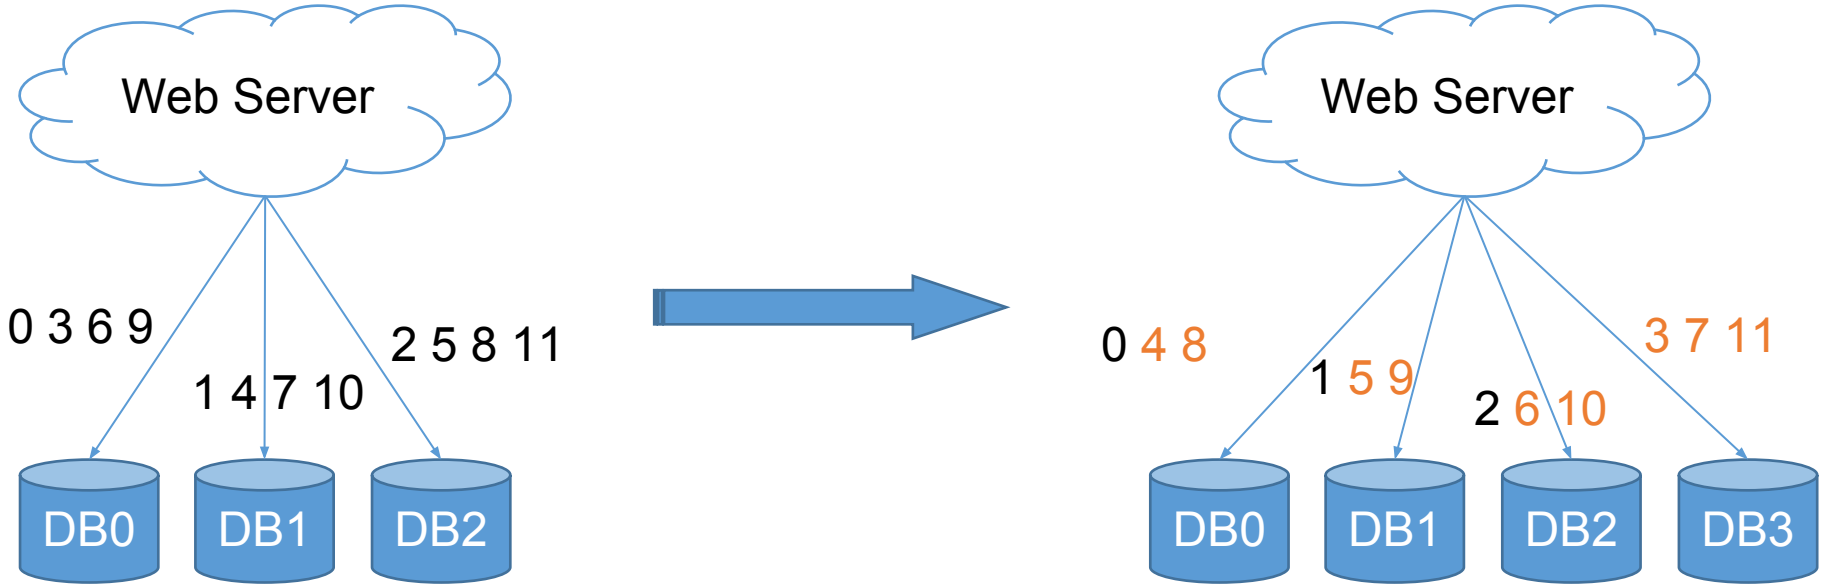

一致性哈希算法 Consistent Hashing

- 一个简单的一致性Hash算法
  - 将 key 模一个很大的数，比如 360
  - 将 360 分配给 n 台机器，每个机器负责一段区间
  - 区间分配信息记录为一张表存在 Web Server 上
  - 新加一台机器的时候，在表中选择一个位置插入，匀走相邻两台机器的一部分数据
- 比如 n 从 2 变化到 3，只有 1/3 的数据移动

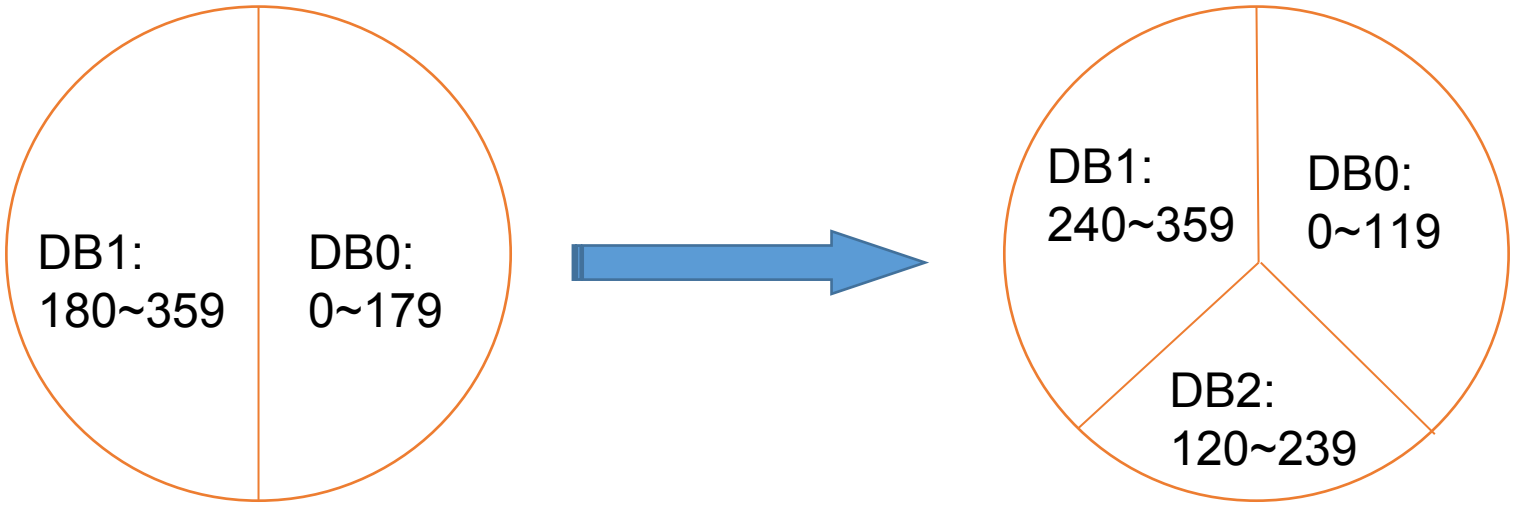

3台机器变4台机器的例子

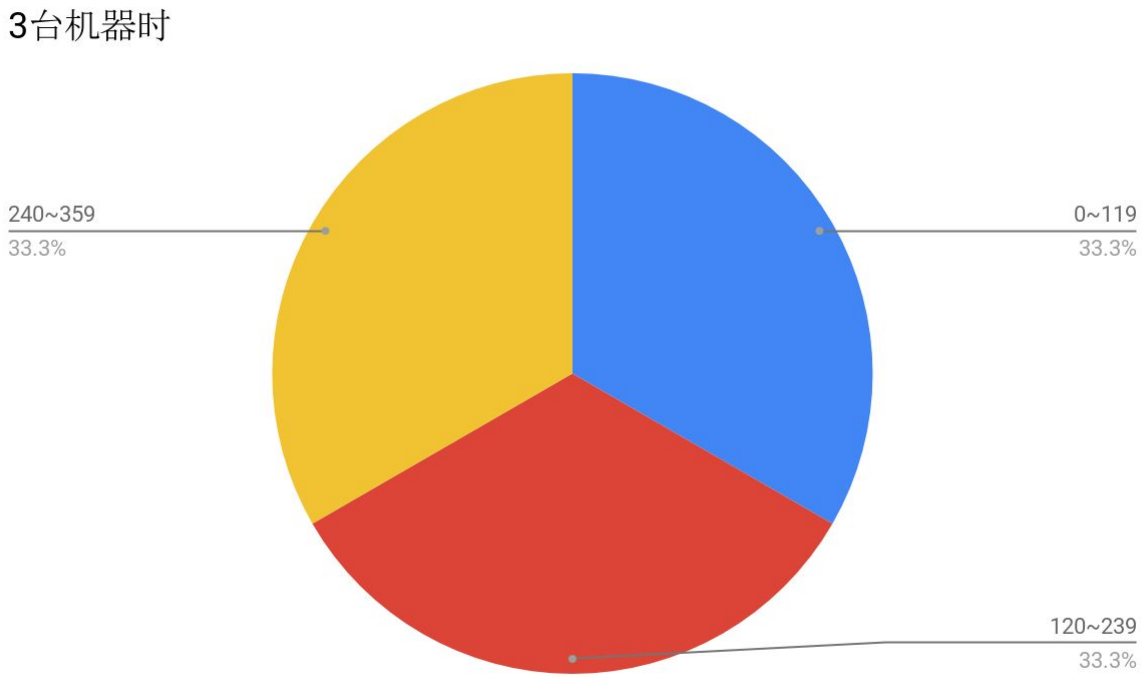

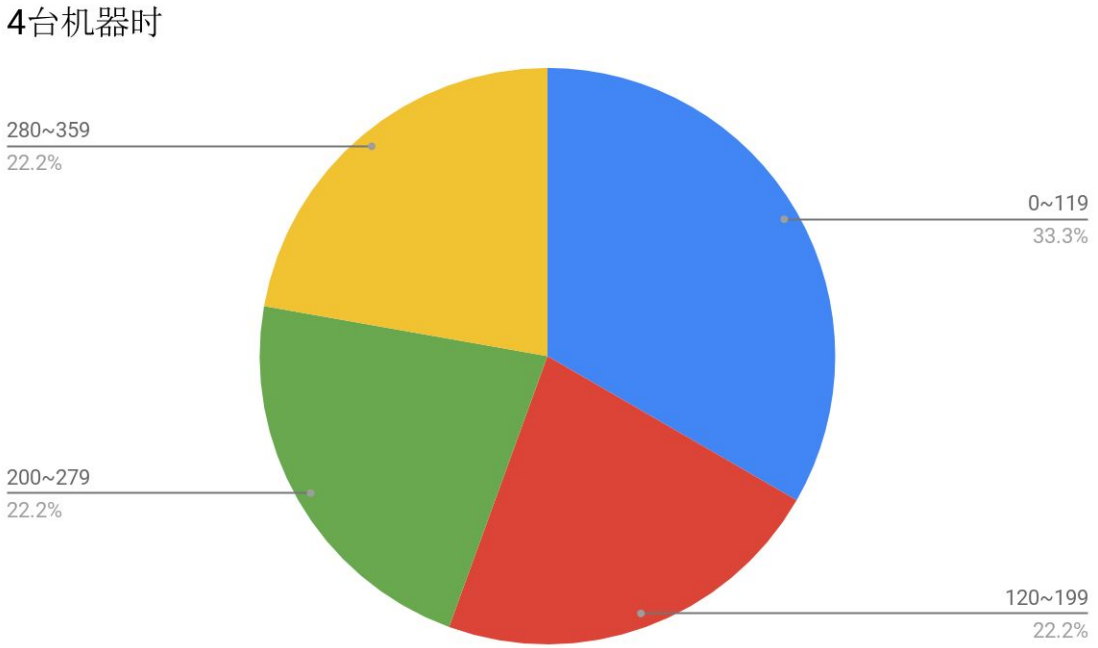

提问:这种方法有什么缺陷？

缺陷1 数据分布不均匀

因为算法是“将数据最多的相邻两台机器均匀分为三台”

比如，3台机器变4台机器时，无法做到4台机器均匀分布

缺陷2 迁移压力大

新机器的数据只从两台老机器上获取

导致这两台老机器负载过大

哈希函数 Hash Function

http://www.lintcode.com/problem/hash-function

将任意类型的 key 转换为一个 0~size-1 的整数

在 Consistent Hashing 中，一般取 size = 2^64

很多哈希算法可以保证不同的 key 算得相同的 hash 值的概率等于

宇宙爆炸的概率

一致性哈希算法 Consistent Hashing

- 将取模的底数从 360 拓展到 2^64
- 将 0~2^64-1 看做一个很大的圆环(Ring)
- 将数据和机器都通过 hash function 换算到环上的一个点
  - 数据取 key / row_key 作为 hash key
  - 机器取MAC地址，或者机器固定名字如 database01，或者固定的 IP 地址
- 每个数据放在哪台机器上，取决于在 Consistent Hash Ring 上**顺时针**碰到的下一个机器节点

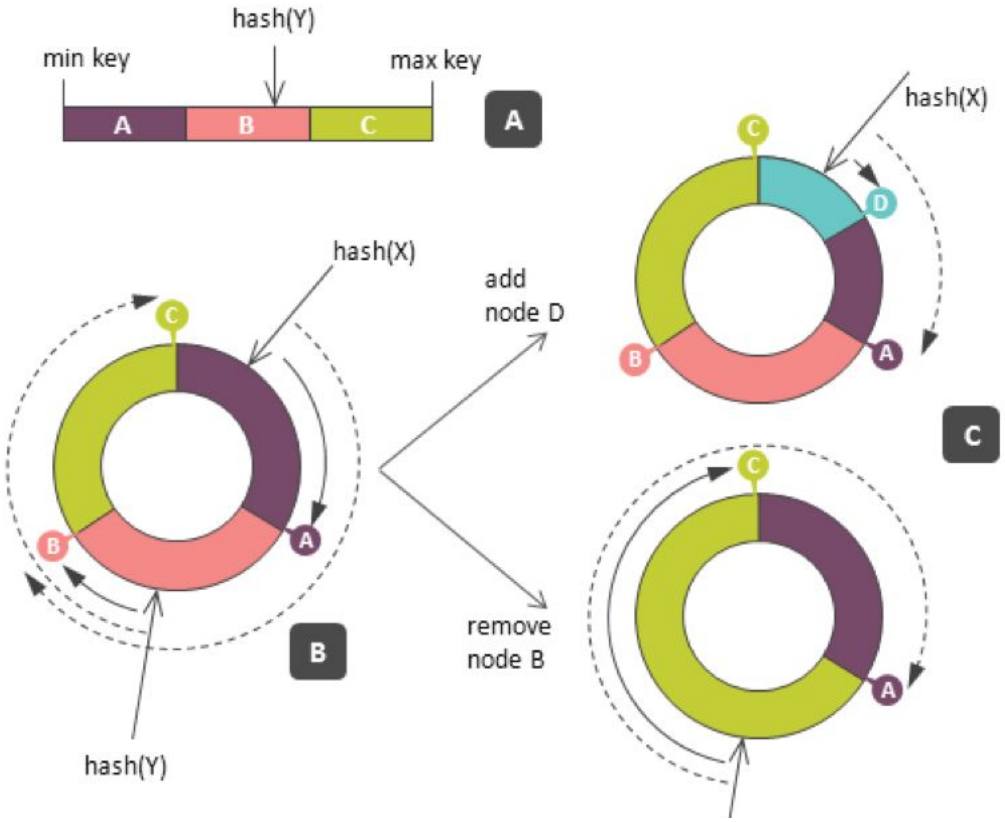

虚拟节点 Virtual Node

- 引入分身的概念(Virtual nodes)
- 一个实体机器(Real node) 对应若干虚拟机器(Virtual Node)
  - 通常是 1000 个
  - 分身的KEY可以用**实体机器的KEY+后缀**的形式
    - 如 database01-0001
    - 好处是直接按格式去掉后缀就可以得到实体机器
- 用一个数据结构存储这些 virtual nodes
  - 支持快速的查询比某个数大的最小数
    - 即顺时针碰到的下一个 virtual nodes
  - 哪种数据结构可以支持？

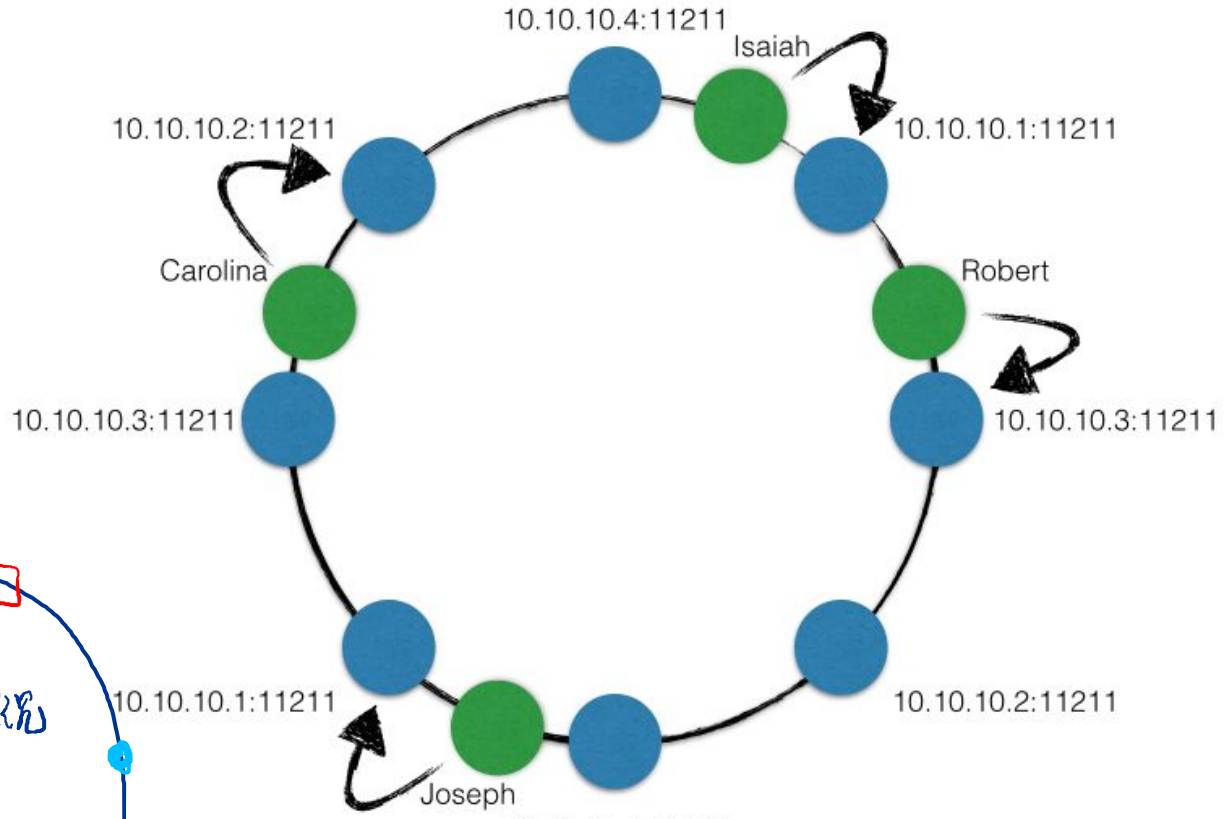

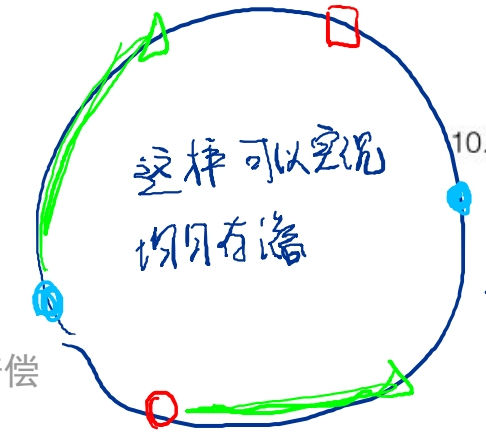

这样一个机器环数一般连续区间 low-discrepency uniform-distribution.

用 Balance-Binary Search Tree 红黑树来存

Consistant hashing 同样request去同样机器
Load Balance 同样data去不同机器

新增一台机器

创建对应的 1000 个分身 db99-000 ~ 999

加入到 virtuals nodes 集合中

问：该从哪些机器迁移哪些数据到新机器上？

Consistent Hashing

http://www.lintcode.com/problem/consistent-hashing-ii/

实现一遍，印象更深刻

Replica 数据备份

问：Backup 和 Replica 有什么区别？

Backup vs Replica

Backup

- 一般是周期性的，比如每天晚上进行一次备份
- 当数据丢失的时候，通常只能恢复到之前的某个时间点
- Backup 不用作在线的数据服务，不分摊读

Replica

- 是实时的，在数据写入的时候，就会以复制品的形式存为多份
- 当数据丢失的时候，可以马上通过其他的复制品恢复
- Replica 用作在线的数据服务，分摊读

思考：既然 Replica 更牛，那么还需要 Backup么？

MySQL Replica

以MySQL为代表SQL型数据库，通常“自带” Master Slave 的 Replica 方法

Master 负责写，Slave 负责读

Slave 从 Master 中同步数据

Master - Slave

- 原理 Write Ahead Log
  - SQL 数据库的任何操作，都会以 Log 的形式做一份记录
  - 比如数据A在B时刻从C改到了D
  - Slave 被激活后，告诉master我在了
  - Master每次有任何操作就通知 slave 来读log
  - 因此Slave上的数据是有“延迟”的
- Master 挂了怎么办？
  - 将一台 Slave 升级 (promote) 为 Master，接受读+写
  - 可能会造成一定程度的数据丢失和不一致

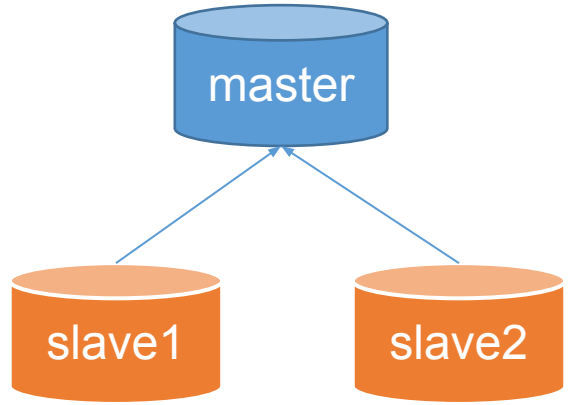

NoSQL Replica

以 Cassandra 为代表的 NoSQL 数据库
通常将数据“顺时针”存储在 Consistent hashing 环上的三个 virtual nodes 中

SQL vs NoSQL in Replica

SQL

“自带” 的 Replica 方式是 Master Slave

“手动” 的 Replica 方式也可以在 Consistent Hashing 环上顺时针存三份

NoSQL

“自带” 的 Replica 方式就是 Consistent Hashing 环上顺时针存三份

“手动” 的 Replica 方式：就不需要手动了，NoSQL就是在 Sharding 和 Replica 上帮你偷懒用的！

实战1：User Table 如何 Sharding

如果我们在 SQL 数据库中存储 User Table

那么按照什么做 Sharding ？

怎么取数据就怎么拆数据

How to shard data based on how to query data

绝大多数请求：select * from user_table where user_id=xxx

问如果我需要按照 username 找用户怎么办？

User Table Sharding 的几个问题

- User Table Sharding 之后，多台数据库无法维护一个全局的**自增ID**怎么办？
  - 手动创建一个 UUID 来作为用户的 user_id
- 创建用户时还没有用户的 user_id，如何知道该去哪个数据库创建呢？
  - Web Server 负责创建用户的 user_id，如用 UUID 来作为 user_id
  - 创建之后根据 consistent_hash(user_id) 的结果来获得所在的实体数据库信息
- 更进一步的问题：如果 User Table 没有 sharding 之前已经采用了自增ID该怎么办？
  - UUID 通常是一个字符串，自增 id 是一个整数，并不兼容
  - 单独用一个 UserIdService 负责创建用户的 ID，每次有新用户需要创建时，问这个 Service 要一个新的 ID。这个 Service 是全局共享的，专门负责创建 UserId。负责记录当前 UserId 的最大值是多少了，然后每次 +1 即可。这个 Service 会负责加锁来保证数据操作的原子性（Atomic）。
  - 因为创建用户不是一个很大的 QPS，因此这个做法问题不大

实战2: Friendship Table 如何 Sharding

双向好友关系是否还能只存储为一条数据？

单向好友关系按照什么 sharding？

实战3：Session Table 如何 Sharding

Session Table 主要包含 session_key(session token), user_id, expire_at 这几项

实战4：News Feed / Timeline 按照什么 Sharding？

News Feed = 新鲜事列表

Timeline = 某人发的所有帖子

实战5：LintCode Submission 按照什么 Sharding

Submission 包含了，谁(user)什么时候(timestamp)提交了哪个题(problem)得到了什么判定结果(status)

实战5：LintCode Submission 如何 Sharding

需求1：查询某个题的所有提交记录

select * from submission_table where problem_id=1001;

需求2：查询某个人的所有提交记录

select * from submission_table where user_id=101;

单纯按照 user_id 或者 problem_id sharding 都无法同时满足两个查询需求。

解决办法（两个表单）：

submission_table 按照 user_id sharding，因为按照 user_id 的查询操作相对频繁一些。

在 submission_table 之外再建立一张表单，记录某个题有哪些提交记录，表单包含 <problem_id, user_id, submission_id, …> 等信息，以 problem_id 作为 sharding key。

Consistent Hashing

http://bit.ly/1XU9uZH

http://bit.ly/1KhqPEr

FAQ:

http://www.jiuzhang.com/qa/1828/

http://www.jiuzhang.com/qa/1417/

http://www.jiuzhang.com/qa/980/

Interviewer: How to limit requests?

如何限制访问次数？
比如 1 小时之类不能重置 >5 次密码

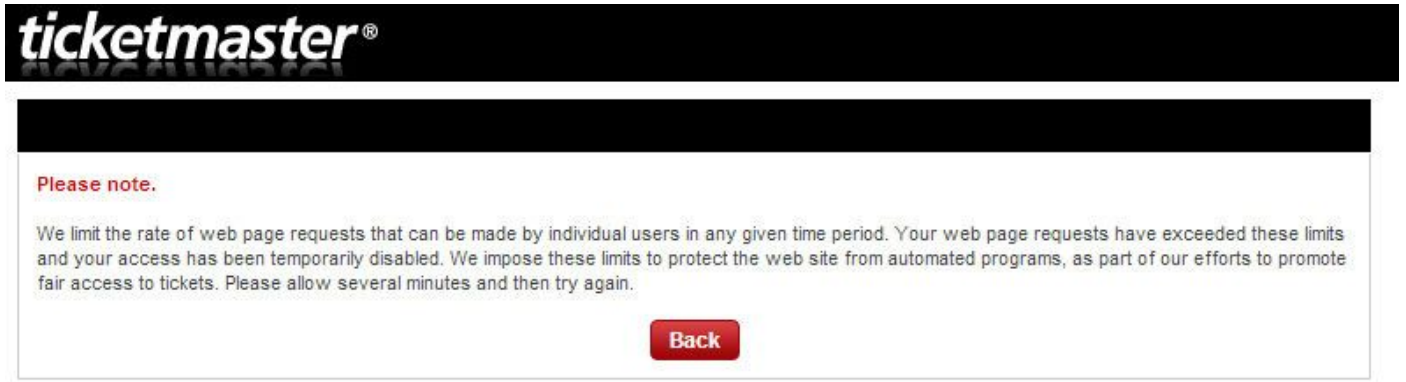

RateLimiter 访问限制器

- Rate limiter
  - 网站必用工具
  - 比如一分钟来自同一个邮箱的密码输入错误不能超过5次，一天不超过10次
- 一些Open source的资源
  - Ruby: https://github.com/ejfinneran/ratelimit
  - Django: https://github.com/jsocol/django-ratelimit
  - 建议：有空读一读源码

- Rate Limiter 已经是一个小型的系统设计问题
- 我们同样可以用 4S 分析法进行分析！

RateLimiter 访问限制器

九章算法

- Scenario 场景
  - 根据网络请求的特征进行限制(feature的选取)
    - IP (未登录时的行为), User(登录后的行为), Email(注册，登录，激活)
  - 系统需要做到怎样的程度
    - 如果在某个时间段内超过了一定数目，就拒绝该请求，返回 4xx 错误
    - 2/s, 5/m, 10/h, 100/d
    - 无需做到最近30秒，最近21分钟这样的限制。粒度太细意义不大
- Service服务
  - 本身就是一个最小的 Application 了，无法再细分
- Storage 数据存取
  - 需要记录(log)某个特征(feature)在哪个时刻(time)做了什么事情(event)
  - 该数据信息最多保留一天(对于 rate=5/m 的限制，那么一次log在一分钟以后已经没有存在的意义了)
  - 必须是可以高效存取的结构(本来就是为了限制对数据库的读写太多，所以自己的效率必须高与数据库)
  - 所以使用 Memcached 作为存储结构(数据无需持久化)

RateLimiter 访问限制器

- 算法描述
- 用 event+feature+timestamp 作为 memcached 的key

- 记录一次访问：
  - 代码：memcached.increament(key, ttl=60s)
  - 解释：将对应bucket的访问次数+1，设置60秒后失效
- 查询是否超过限制
  - 代码：
  - for t in 0~59 do
    - key = event+feature+(current_timestamp – t)
    - sum+= memcahed.get(key, default=0)
  - Check sum is in limitation
  - 解释：把最近1分钟的访问记录加和

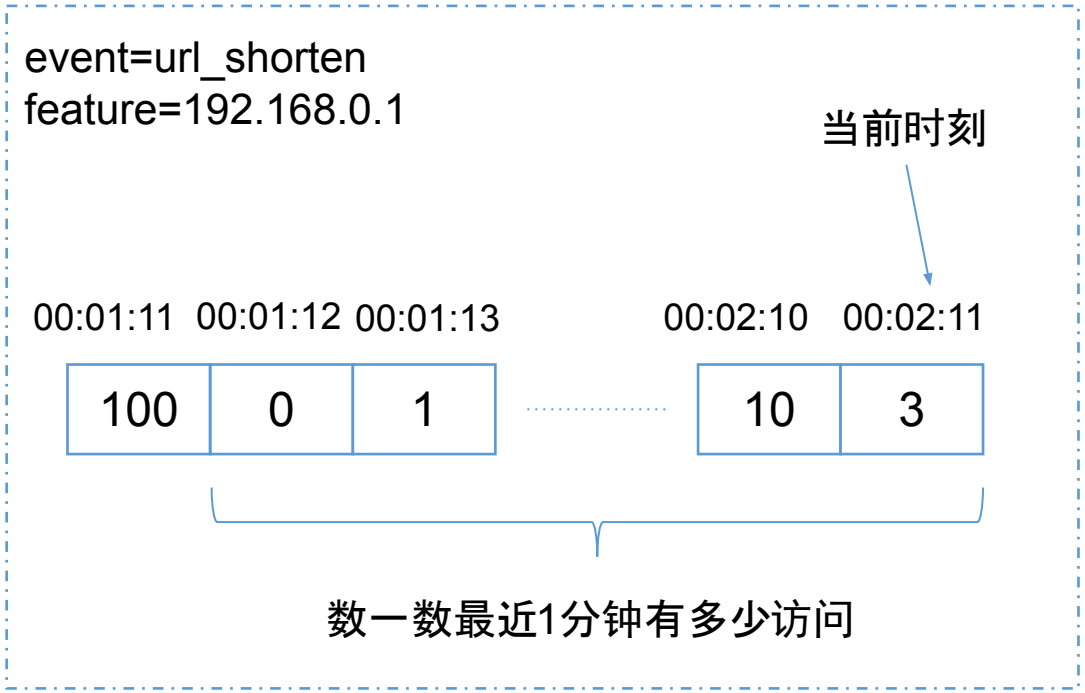

RateLimiter 访问限制器

- 问：对于一天来说，有86400秒，检查一次就要 86k 的 cache 访问，如何优化？
- 答：分级存储。
  - 之前限制以1分钟为单位的时候，每个bucket的大小是1秒，一次查询最多60次读
  - 现在限制以1天为单位的时候，每个bucket以小时为单位存储，一次查询最多24次读
  - 同理如果以小时为单位，那么每个bucket设置为1分钟，一次查询最多60次读
- 问：上述的方法中存在误差，如何解决误差？
  - 首先这个误差其实不用解决，访问限制器不需要做到绝对精确。
  - 其次如果真要解决的话，可以将每次log的信息分别存入3级的bucket（秒，分钟，小时）
  - 在获得最近1天的访问次数时，比如当前时刻是23:30:33，加总如下的几项：
    - 在秒的bucket里加和 23:30:00 ~ 23:30:33（计34次查询）
    - 在分的bucket里加和 23:00 ~ 23:29（计30次查询）
    - 在时的bucket里加和 00 ~ 22（计23次查询）
    - 在秒的bucket里加和昨天 23:30:34 ~ 23:30:59（计26次查询）
    - 在分的bucket里加和昨天 23:31 ~ 23:59（计29次查询）
    - 总计耗费 34 + 30 + 23 + 26 + 29 = 142 次cache查询，可以接受

你觉得是否需要解决误差？

Interviewer: Design Datadog (Monitor System)

怎样统计访问数据？

- https://www.datadoghq.com/
- 同样进行 4S 分析！
- Scenario 设计些啥
  - 对于用户对于某个链接的每次访问，记录为一次访问
  - 可以查询某个链接的被访问次数
  - 知道总共多少次访问
  - 知道最近的x小时/x天/x月/x年的访问曲线图
  - 假设 Tiny URL 的读请求约 2k 的QPS
- Service
  - 自身为一个独立的Application，无法更细分

怎样统计访问数据？

- Storage
  - 基本全是写操作，读操作很少
  - 需要持久化存储（没memcached什么事儿了）
  - SQL or NoSQL or File System?
    - 其实都可以，业界的一些系统比如 Graphite 用的是文件系统存储
    - 这里我们假设用NoSQL存储吧
  - 用NoSQL的话，key 就是 tiny url 的 short_key，value是这个key的所有访问记录的统计数据
    - 你可能会奇怪为什么value可以存下一个key的所有访问数据（比如1整年）
  - 我们来看看value的结构
  - 核心点是：
    - 今天的数据，我们以分钟为单位存储
    - 昨天的数据，可能就以5分钟为单位存储
    - 上个月的数据，可能就以1小时为单位存储
    - 去年的数据，就以周 为单位存储
    - …
    - **用户的查询操作通常是查询某个时刻到当前时刻的曲线图**
    - **也就意味着，对于去年的数据，你没有必要一分 钟一分钟的进行保存**
  - 多级Bucket的思路，是不是和Rate Limiter如出一辙！

```
…
2016/02/26 23 1h 200
…
2016/03/27 23:50 5m 40
2016/03/27 23:55 5m 30
2016/03/28 00:00 1m 10
2016/03/28 00:01 1m 21
…
2016/03/28 16:00 m 2
```